

Praktikumsbericht

Canny Edge Detection auf der GPU

Matthias Stefan

Thomas Jurczyk

30. Juni 2026

Inhaltsverzeichnis

1	Voraussetzungen und Projektaufbau	3
1.1	Hardware-Spezifikationen	3
1.2	Projektstruktur	3
1.3	Build-System und Kompilierung	3
1.4	Messmethodologie	3
2	Algorithmus	4
2.1	Überblick	4
2.2	Schritte	4
2.2.1	Schritt 1: Gaussian Blur	4
2.2.2	Schritt 2: Sobel	4
2.2.3	Schritt 3: Non-Maximum Suppression	4
2.2.4	Schritt 4: Hysteresis	5
3	Implementierung	6
3.1	Schritt 1: Gaussian Blur	6
3.1.1	Naive Implementierung	6
3.1.2	Shared Memory Optimierung	7
3.1.3	Pinned Memory Optimierung	7
3.1.4	Warp-Level Optimierung	7
3.2	Schritt 2: Sobel	8
3.3	Schritt 3: Non-Maximum Suppression	8
3.3.1	Schritt 4: Hysteresis	9
4	Ergebnisse und Analyse	10
4.1	Gaussian Blur	10
4.1.1	Korrektheit	10
4.1.2	Performance	10
4.2	Schritt 2: Sobel	11
4.3	Schritt 3: Non-Maximum Suppression	11
4.4	Schritt 4: Hysteresis	11
5	Fazit	12

5.1	Fazit	12
	Anhang	14

1 Voraussetzungen und Projektaufbau

1.1 Hardware-Spezifikationen

1.2 Projektstruktur

1.3 Build-System und Kompilierung

1.4 Messmethodologie

Die Performance-Messungen wurden unter nicht-isolierten Bedingungen durchgeführt. Folgende Faktoren können die Ergebnisse beeinflusst haben:

- Hintergrundprozesse liefen parallel zur Messung
- Thermisches Throttling durch unkontrollierte GPU-Temperatur
- Dynamisches Power Management der Laptop-GPU
- Nicht garantiert geleerte CPU- und GPU-Caches zwischen den Runs
- OS-Scheduling-Interrupts, insbesondere bei $H \rightarrow D/D \rightarrow H$ Transfers

Die Ergebnisse sind daher als Richtwerte zu verstehen. Um Schwankungen zu minimieren, wurde jede Messung als Durchschnitt über 200 Runs ermittelt. Der erste Aufruf (Warm-up Run) wird separat ausgewiesen, da CUDA-Kontext und Page-Cache zu diesem Zeitpunkt noch nicht aufgewärmt sind. NCU-Profilng wurde mit 10 Kernel-Instanzen pro Report durchgeführt, der Warm-up Run ausgeschlossen.

2 Algorithmus

2.1 Überblick

Der Canny-Algorithmus ist ein mehrstufiges Verfahren zur Kantendetektion in Graustufenbildern. Canny definiert drei Kriterien für einen optimalen Kantendetektor: gute Detektion, präzise Lokalisierung sowie exakt eine Antwort pro Kante, die auf eine Breite von einem Pixel supprimiert werden soll [1, S. 680]. Die Verarbeitung erfolgt in vier aufeinanderfolgenden Schritten, wobei der Output jedes Schritts als Input des nächsten dient (siehe Abbildung 1). Die einzelnen Schritte werden in den kommenden Abschnitten näher erläutert.




Abbildung 1: Canny Edge Detection Pipeline

2.2 Schritte

2.2.1 Schritt 1: Gaussian Blur

Um einen mathematisch optimalen Kantendetektor herzuleiten, trifft Canny eine Annahme über das Rauschen im Bild: „*We will assume that the image consists of the edge and additive white Gaussian noise*“ [1, S. 680]. Da dieses Rauschen fälschlicherweise als Kante detektiert werden kann, muss das Bild zunächst geglättet werden. Canny zeigt, dass der optimale Filter für dieses Rauschmodell durch die erste Ableitung einer Gaußfunktion approximiert werden kann [1, S. 687]:

$$G(x) = \exp\left(-\frac{x^2}{2\sigma^2}\right) \quad (1)$$

Der Parameter σ kontrolliert die Stärke der Glättung. Zwischen Rauschunterdrückung und Lokalisierungsgenauigkeit besteht jedoch ein grundlegender Zielkonflikt, den Canny als „*uncertainty principle*“ zwischen Detektion und Lokalisierung bezeichnet [1, S. 684].

2.2.2 Schritt 2: Sobel

2.2.3 Schritt 3: Non-Maximum Suppression

Schritt 2 liefert für jeden Pixel einen Gradientenbetrag, der die lokale Kantenstärke beschreibt, die resultierenden Kanten sind dabei an vielen Stellen breiter als ein Pixel. Canny fordert jedoch präzise Lokalisierung: „*The points marked as edge points by the operator should be as close as possible to the center of the true edge*“ [1, S. 680]. Non-Maximum Suppression reduziert diese breite Gradientenantwort auf eine Breite von einem Pixel, indem entlang der Gradientenrichtung nur das lokale Maximum erhalten bleibt.

Formal lässt sich der gesuchte Kantenpunkt als Nullstelle der zweiten Richtungsableitung des geglätteten Bildes beschreiben:

$$\frac{\partial^2}{\partial n^2}(G * I) = 0 \quad (2)$$

wobei n die Richtung des Gradienten bezeichnet und $G * I$ das geglättete Bild [1, S. 691]. Die Nullstelle der zweiten Ableitung markiert exakt den Punkt, an dem die erste Ableitung, die Gradientenstärke entlang n , ihr lokales Maximum besitzt. Da die Kantenrichtung n nicht vorab bekannt ist, wird sie aus der geglätteten Gradientenrichtung geschätzt [1, Gl. 46, S. 691]:

$$n = \frac{\nabla(G * I)}{|\nabla(G * I)|} \quad (3)$$

In der diskreten Implementierung wird Gleichung 2 approximiert, indem die Gradientenmagnitude $|\nabla(G * I)|$ jedes Pixels mit den beiden direkten Nachbarn entlang der auf vier Klassen ($0^\circ/45^\circ/90^\circ/135^\circ$) quantisierten Gradientenrichtung verglichen wird. Ein Pixel überlebt die Suppression genau dann, wenn seine Magnitude größer oder gleich beiden Nachbarn ist, andernfalls wird er auf null gesetzt.

2.2.4 Schritt 4: Hysteresis

3 Implementierung

3.1 Schritt 1: Gaussian Blur

3.1.1 Naive Implementierung

Die Gaußgewichte werden zunächst auf der CPU als zweidimensionales Raster der Größe $(2 \cdot \text{BLUR_RADIUS} + 1)^2$ vorberechnet und normalisiert, sodass ihre Summe 1 ergibt und die Bildhelligkeit erhalten bleibt (Gleichung 1). Das Gewichtsraster wird einmalig vor dem Kernelaufruf per `cudaMemcpy` auf die GPU übertragen und steht dort allen Threads als Read-only-Buffer im globalen Speicher zur Verfügung. Das resultierende 3×3 Gewichtsraster für $\sigma = 1.0$ ist in Abbildung 2 dargestellt.




Abbildung 2: Gaussian Blur, gewichteter Mittelwert am Beispielpixel L48 $\rightarrow$ L34

Im CUDA-Kernel `gaussian_filter()` ist jeder Thread für genau einen Ausgabepixel zuständig. Die Thread-Position ergibt sich aus `blockIdx` und `threadIdx` (Listing 1, Zeile 1–2), Threads außerhalb der Bildgrenzen werden sofort verworfen (Zeile 3). Jeder Thread iteriert anschließend über alle $(2r + 1)^2$ Nachbarpixel, liest jeden Wert direkt aus dem globalen Speicher und akkumuliert die gewichtete Summe (Zeile 5–10). Pixel außerhalb der Bildgrenzen werden mit 0 aufgefüllt (Zero-Padding). Das Ergebnis wird in den Ausgabepuffer geschrieben (Zeile 12).

```

1 x = blockIdx.x * blockDim.x + threadIdx.x
2 y = blockIdx.y * blockDim.y + threadIdx.y
3 if (x, y) ausserhalb des Bildes: return
4
5 color = 0.0
6 for j = -radius to +radius:
7     for i = -radius to +radius:
8         if (x+i, y+j) innerhalb des Bildes:
9             pixel = src_buffer[(y+j) * width + (x+i)]
10            color += pixel * weights[(j+r) * blur_size + (i+r)]
11
12 out_buffer[y * width + x] = color

```

Listing 1: Pseudocode, `gaussian_filter` Kernel (naive)

Die Threads eines Blocks greifen dabei in y-Richtung auf Adressen mit Abstand `width` zu, wodurch die Zugriffe auf den globalen Speicher nicht coalesced erfolgen. Dies motiviert die Shared Memory Optimierung in Abschnitt 3.1.2; die quantitative Auswertung findet sich in Abschnitt 4.1.

3.1.2 Shared Memory Optimierung

Der zentrale Engpass der naiven Implementierung sind die uncoalesced Global Memory Zugriffe: bei einem Kernel der Größe $(2r + 1)^2$ liest jeder Thread bis zu $(2r + 1)^2$ Pixel aus dem DRAM, wobei Pixel die von mehreren Threads benötigt werden redundant geladen werden. Horvath et al. adressieren dieses Problem durch Shared Memory Tiling, bei dem Threads eines Blocks kooperativ eine Bildkachel in den schnellen On-Chip Speicher laden, bevor die eigentliche Faltung beginnt [2, S. 2].

Die Kachel hat die Größe $(\text{BLOCK_SIZE} + 2 \cdot \text{BLUR_RADIUS})^2$ und enthält neben den eigentlichen Ausgabepixeln des Blocks auch den sogenannten Halo-Rand. Da die Kachel größer ist als der Block selbst, lädt jeder Thread mittels eines Stride-Loops einen oder mehrere Pixel in den Shared Memory. Nach dem Laden wird `__syncthreads()` aufgerufen, um sicherzustellen, dass alle Threads ihre Pixel geschrieben haben bevor die Faltung beginnt. Die Gaußgewichte werden zusätzlich in `__constant__` Memory ausgelagert, da alle Threads exakt dieselben Gewichte lesen und `__constant__` Memory für uniforme Zugriffe hardwareseitig gecacht wird.

Die drei wesentlichen Änderungen gegenüber der naiven Implementierung sind:

- `__shared__ uint8_t tile[tile_size * tile_size]`, eine kooperativ geladene Bildkachel inklusive Halo-Rand der Breite `BLUR_RADIUS`
- `__syncthreads()`, Synchronisationsbarriere nach dem kooperativen Laden
- `__constant__ float device_weights[...]`, Gaußgewichte in Constant Memory, Upload per `cudaMemcpyToSymbol()`

Die Auswirkung dieser Optimierung auf Laufzeit und Speicherdurchsatz wird in Abschnitt 4.1 ausgewertet.

3.1.3 Pinned Memory Optimierung

Pinned Memory (Page-locked Memory) ist Host-seitiger Speicher, der vom Betriebssystem nicht ausgelagert werden kann, wodurch direkte DMA-Transfers ohne zwischengeschalteten CPU-Cache möglich sind. Die Änderung gegenüber der Shared Memory Implementierung beschränkt sich ausschließlich auf die Host-seitige Allokation (`cudaMallocHost()` statt `malloc()`), der Kernel bleibt identisch. Der erwartete Vorteil zeigt sich primär beim Device-to-Host-Transfer (siehe Abschnitt 4.1).

3.1.4 Warp-Level Optimierung

Als vierte Optimierungsstufe wurden Warp-Level Intrinsics (`__shfl_sync()`) evaluiert. Diese ermöglichen den direkten Datenaustausch zwischen Threads innerhalb eines Warps ohne Shared Memory und ohne `__syncthreads()`.

Für 2D-Stencil-Operationen wie den Gaussian Blur ist dieser Ansatz jedoch nicht geeignet, da `__shfl_sync()` primär für 1D-Reduktionen konzipiert ist und bei zweidimensionalen Nachbarschaftszugriffen keinen strukturellen Vorteil bietet. Yadav et al. bestätigen dies: in ihren Messungen erreicht die Warp-Variante 79.29 % Compute/Memory Throughput, während Shared Memory 83.33 % erzielt [3]. Eine eigene Implementierung wurde daher nicht vorgenommen.

3.2 Schritt 2: Sobel

3.3 Schritt 3: Non-Maximum Suppression

Die Non-Maximum Suppression wird im CUDA-Kernel `non_maximum_suppression()` umgesetzt. Jeder Thread ist dabei für genau einen Pixel zuständig, die Thread-Position ergibt sich wie in Schritt 1 und 2 aus `blockIdx` und `threadIdx`. Als Input erhält der Kernel den Gradientenbetrag (`magnitude_buffer`) sowie die Gradientenrichtung in Radiant (`direction_buffer`) aus Schritt 2.

Zunächst wird die Gradientenrichtung von Radiant in Grad umgerechnet und auf den Bereich $[0^\circ, 180^\circ)$ gefaltet, da eine Kante keine Orientierung besitzt, eine Kante bei 170° und eine bei -10° beschreiben dieselbe Achse. Anschließend wird die Richtung auf eine von vier Klassen quantisiert, die den vier möglichen Achsen im diskreten Pixelraster entsprechen (siehe Abbildung 3).

Je nach Richtungsklasse werden die Offsets (dx, dy) zum Nachbapixel bestimmt (Listing 2, Zeile 18–22). Der Pixel überlebt die Suppression genau dann, wenn seine Magnitude größer oder gleich beiden Nachbarn entlang dieser Achse ist (Zeile 24–26), andernfalls wird er auf null gesetzt:

```
1  __global__ void non_maximum_suppression(  
2      const uint8_t* magnitude_buffer,  
3      const float* direction_buffer,  
4      const int32_t width,  
5      const int32_t height,  
6      uint8_t* out_nms_buffer)  
7  {  
8      const auto x = static_cast<int32_t>(blockIdx.x * blockDim.x + threadIdx.x);  
9      const auto y = static_cast<int32_t>(blockIdx.y * blockDim.y + threadIdx.y);  
10     if (x >= width || y >= height)  
11         return;  
12  
13     const uint8_t magnitude = magnitude_buffer[y * width + x];  
14     const float direction = direction_buffer[y * width + x];  
15  
16     float deg = direction * (180.0f / CUDART_PI_F);  
17     deg = fmodf(deg + 180.0f, 180.0f);  
18  
19     int32_t dx, dy;  
20     if (deg < 22.5f) { dx = 1; dy = 0; }  
21     else if (deg < 67.5f) { dx = 1; dy = -1; }  
22     else if (deg < 112.5f) { dx = 0; dy = 1; }  
23     else if (deg < 157.5f) { dx = 1; dy = 1; }  
24     else { dx = 1; dy = 0; }  
25  
26     const uint8_t neighbor_a =  
27         sample_clamped(magnitude_buffer, width, height, x + dx, y + dy);  
28     const uint8_t neighbor_b =  
29         sample_clamped(magnitude_buffer, width, height, x - dx, y - dy);  
30  
31     out_nms_buffer[y * width + x] =  
32         (magnitude >= neighbor_a && magnitude >= neighbor_b) ? magnitude : 0;  
33 }
```

Listing 2: non_maximum_suppression Kernel




Abbildung 3: Non-Maximum Suppression: Die Gradientenrichtung wird auf eine von vier Achsen quantisiert (0° , 45° , 90° , 135°). Anschließend wird der Pixel mit den beiden farbig markierten Nachbarn entlang der gewählten Achse verglichen.

Das Ergebnis der Non-Maximum Suppression ist in Abbildung 4 dargestellt. Im Vergleich zur Gradientenmagnitude aus Schritt 2 sind die Kanten auf eine Breite von einem Pixel reduziert.



Abbildung 4: Vergleich Gradientenmagnitude (links) vs. Non-Maximum Suppression (rechts), die breite Gradientenantwort wird auf eine Breite von einem Pixel reduziert. (Placeholder – wird ersetzt)

3.3.1 Schritt 4: Hysteresis

4 Ergebnisse und Analyse

4.1 Gaussian Blur

4.1.1 Korrektheit

Abbildung 5 zeigt das Ergebnis der Filterung im Vergleich zum Originalbild.



Abbildung 5: Vergleich Original (links) vs. Gaussian Blur (rechts, $\sigma = 25$, `BLUR_RADIUS=12`). Die Parameter wurden bewusst extrem gewählt, um den Effekt deutlicher sichtbar zu machen, in der Pipeline wird ein deutlich sanfterer Filter verwendet.

4.1.2 Performance

Das NCU-Profil der naiven Implementierung zeigt, dass 47 % aller Global Memory Zugriffe uncoalesced sind, was die in Abschnitt 3.1.2 beschriebene Shared Memory Optimierung motiviert.

Der gemessene Speedup hängt stark vom `BLUR_RADIUS` ab (siehe Abbildung 6). Bei $r = 2$ überwiegt der `__syncthreads()`-Overhead, die Kernel-Laufzeit sinkt nur marginal von 1.67 ms auf 0.99 ms bei nahezu identischem SM Throughput (68.31 % vs. 66.25 %). Bei $r = 9$ kehrt sich das Verhältnis um: die $(2 \cdot 9 + 1)^2 = 361$ Operationen pro Pixel machen den redundanten DRAM-Traffic zum dominanten Faktor, die Kernel-Laufzeit sinkt von 22.67 ms auf 7.54 ms ($3.0\times$ Speedup), der SM Throughput steigt von 64.66 % auf 91.50 %. Die vollständigen Messdaten sind in Anhang A (S. 14) aufgeführt.

Die Pinned-Memory-Variante bestätigt, dass Compute Throughput und Occupancy bei $r = 9$ mit 91.46 % bzw. 94.83 % praktisch identisch zur Shared Memory Variante sind (91.50 % bzw. 94.84 %), was sich dadurch erklärt, dass der Kernel selbst unverändert bleibt. Der Vorteil zeigt sich ausschließlich im D→H Transfer, der bei $r = 9$ von 2.04 ms auf 1.37 ms sinkt, und im Gesamttiming von 11.95 ms auf 10.75 ms. Die vollständigen Messdaten sind im Anhang A (S. 14) aufgeführt.




Abbildung 6: NCU-Profling, Vergleich naive/shared/pinned bei $r=2$ und $r=9$ (200 Runs Avg).

4.2 Schritt 2: Sobel

4.3 Schritt 3: Non-Maximum Suppression

4.4 Schritt 4: Hysteresis

5 Fazit

5.1 Fazit

Literatur

- [1] John Canny. A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8(6):679–698, November 1986.
- [2] Matthew Horvath, Michael Bowers, and Shadi Alawneh. Canny edge detection on gpu using cuda. In *2023 IEEE 13th Annual Computing and Communication Workshop and Conference (CCWC)*, pages 0419–0425, 2023.
- [3] Rishita Yadav and Harshul Gupta. Optimizing CUDA kernels for high-performance canny edge detection. *International Journal of Science, Engineering and Technology*, 13(4), 2025.

Anhang

A: Performance-Rohdaten Gaussian Blur

Metrik	naive	shared	pinned
<i>Warm-up Run</i>			
H→D [ms]	3.062	5.660	2.709
Kernel [ms]	2.606	1.697	1.688
D→H [ms]	7.631	7.020	2.502
Total [ms]	13.299	14.377	6.899
<i>200 Runs Avg</i>			
H→D [ms]	3.548	3.475	3.135
Kernel [ms]	1.669	0.990	0.987
D→H [ms]	3.068	3.001	1.740
Total [ms]	8.286	7.466	5.862

Tabelle 1: cudaEvent-Messungen, BLUR_RADIUS = 2

Metrik (NCU, 10 Runs Avg)	naive	shared	pinned
Compute (SM) Throughput [%]	68.31	66.25	66.54
Memory Throughput [%]	61.10	66.25	66.54
DRAM Throughput [%]	5.81	8.42	7.60
Achieved Occupancy [%]	76.50	92.67	92.65
Warp Cycles Per Issued Instruction	8.79	16.46	16.33
L1/TEX Hit Rate [%]	92.94	27.32	27.29
L2 Hit Rate [%]	87.75	88.17	89.12

Tabelle 2: NCU-Profling, BLUR_RADIUS = 2

Metrik	naive	shared	pinned
<i>Warm-up Run</i>			
H→D [ms]	2.589	1.757	1.781
Kernel [ms]	35.700	12.575	13.182
D→H [ms]	6.035	6.183	1.836
Total [ms]	44.324	20.515	16.799
<i>200 Runs Avg</i>			
H→D [ms]	2.512	2.375	2.057
Kernel [ms]	22.669	7.537	7.325
D→H [ms]	2.142	2.036	1.366
Total [ms]	27.308	11.948	10.747

Tabelle 3: cudaEvent-Messungen, BLUR_RADIUS = 9

Metrik (NCU, 10 Runs Avg)	naive	shared	pinned
Compute (SM) Throughput [%]	64.66	91.50	91.46
Memory Throughput [%]	64.66	91.50	91.46
DRAM Throughput [%]	1.06	1.69	1.79
Achieved Occupancy [%]	95.52	94.84	94.83
Warp Cycles Per Issued Instruction	12.56	13.78	13.77
L1/TEX Hit Rate [%]	99.27	45.55	45.54
L2 Hit Rate [%]	63.36	82.96	87.35

Tabelle 4: NCU-Profilng, BLUR_RADIUS = 9